

위성 센서의 물리적 열화 및 분광 특성을 반영한 Prithvi-EO-2.0 기반 Sentinel-2 초해상화 프레임워크

A Prithvi-EO-2.0 Based Sentinel-2 Super-Resolution Framework Reflecting Physical Degradation and Spectral Characteristics of Satellite Sensors

이동언¹ · 김범식¹ · 이두현¹

Dongun Lee¹ · Beomsik Kim¹ · Dohyeon Lee¹

¹서울시립대학교 공간정보공학과 (lde0267@uos.ac.kr)

¹서울시립대학교 공간정보공학과 (kbs0215@uos.ac.kr)

¹서울시립대학교 공간정보공학과 (2016up@uos.ac.kr)

초 록

KOMPSAT-3A(K3A)와 같은 고해상도 위성 영상은 정밀 관측이 가능하나, 좁은 관측폭과 긴 재방문 주기로 인해 광역 모니터링 시 높은 비용과 시간적 제약이 따른다. 이를 극복하기 위해 광역·고빈도 관측이 가능한 Sentinel-2(S2) 영상에 딥러닝 기반 초해상화(Super-Resolution)를 적용하는 연구가 주목받고 있다. 기존 초해상화 연구는 Bicubic 기반 인위적 다운샘플링으로 학습쌍을 구성하고 일반 이미지로 사전 학습된 모델에 의존하여, 실제 센서 간 도메인 불일치 및 원격탐사 도메인 지식 부재라는 한계를 지닌다. 본 연구에서는 K3A 영상에 방사 모사 및 MTF 기반 열화 모사를 순차 적용하여 Sentinel-2의 물리적 특성을 재현한 학습 데이터셋을 구축하고, Geo Foundation Model인 Prithvi-EO-2.0을 인코더로 활용한 초해상화 프레임워크를 제안한다. 실험 결과, 영상모사에서 NIR 밴드에서 MAE가 0.0700에서 0.0519로 감소하는 등 전 밴드에서 Bicubic 대비 일관된 오차 감소를 보였다. 또한 제안 모델은 Bicubic 보간법 대비 PSNR +5.50dB, SSIM +0.055 등 유의미한 성능 향상을 달성하며 화질 개선과 구조적 유사도, 분광보존 능력을 확인하였다.

1. 서론

최근 도시 변화 탐지, 농업·산림 모니터링 등 다양한 지표 분석 분야에서 VHR 위성 영상에 대한 수요가 증가하고 있다 (Qiu et al., 2025; Ali et al., 2024). 그러나 광학 센서의 물리적 특성상 공간 해상도와 관측 폭 사이에는 필연적인 트레이드오프가 존재한다. 국내 VHR 위성인 KOMPSAT-3A(KARI 운용)는 전정색 기준 0.55m의 해상도를 제공하지만, 관측 폭 약 12km·재방문 주기 28일 이상이라는 제약으로 광역 커버리지 확보에 상당한 비용과 시간적 불연속성이 수반된다 (EEA, 2020).

이에 대한 대안으로, ESA의 다중분광 위성 Sentinel-2는 290km의 광역 관측 폭과 5일의 재방문 주기를 제공하며, 이 영상에 딥러닝 기반 초해상화를 적용하여 공간 해상도를 향상시키는 접근이 주목받고 있다 (Gasperini et al., 2022). 그러나 기존 초해상화 모델은 Bicubic 보간법 기반의 인위적 보간법으로 학습 데이터를 구축하므로, 실제 관측 환경의 센서 노이즈·PSF·분광 차이를 반영하

지 못해 학습-추론 간 도메인 간극을 유발한다 (Nguyen et al., 2023). 아울러 기존 원격탐사 초해상화 연구는 ImageNet 등 일반 이미지 데이터로 사전 학습된 모델을 전이 학습하는 방식에 의존하는 경우가 많아, 원격탐사 고유의 다중 분광 특성과 지리공간적 맥락을 내재화하지 못함으로써 분광 왜곡 및 구조적 복원 오류를 초래할 수 있다 (Jakubik et al., 2024).

따라서 본 연구에서는 센서 간 물리적 열화를 학습 단계에서 재현하고, 원격탐사 도메인에 특화된 파운데이션 모델과 결합하는 초해상화 프레임워크를 제안한다. 구체적으로, KOMPSAT-3A 영상에 방사 모사 및 MTF 기반 열화를 순차 적용하여 Sentinel-2의 물리적 특성을 재현한 학습 데이터셋을 구축하고, Geo Foundation Model인 Prithvi-EO-2.0 (Jakubik et al., 2024)을 인코더로 활용한 초해상화 모델을 설계한다. 이후 학습된 모델로 S2 영상을 K3A 해상도 수준으로 초해상화하고, Bicubic 보간법 대비 공간·분광 성능을 정량적으로 검증한다.




Figure 1. Overall workflow of the proposed super-resolution framework: Phase 1 — data input and alignment, Phase 2 — dataset construction via radiometric and degradation simulation, Phase 3 — model architecture with Prithvi encoder and hybrid attention decoder

2. 연구방법

2.1. 학습 데이터셋 구축

A. 데이터 수집

본 연구는 학습 데이터의 지역적 대표성을 확보하기 위해 토지피복이 상이한 서울, 대전, 김제를 대상으로 선정하였다. 고해상도 타겟 영상으로는 KOMPSAT-3A(GSD 약 2.2 m)를, 저해상도 참조 영상으로는 Sentinel-2(GSD 10 m)를 활용하였다. Sentinel-2 영상 선정 시 구름량 10% 이하, KOMPSAT-3A 촬영일 기준 ± 10 일 이내의 조건을 적용하였다. 또한 방사적 일관성을 유지하기 위해 K3A와 S2 모두 대기 상단 반사도(top-of-atmosphere reflectance) 산출물로 각각 Level-1R, Level-1C를 채택하였으며 좌표계는 WGS 84 (EPSG:32652)로 통일하였다.




Figure 2. KOMPSAT-3A imagery of study: (a) Seoul (high-density urban), (b) Seoul, (c) Daejeon (urban-rural mixed), (d) Gimje (agricultural)

B. 공통 기준 격자 정렬 및 정합

KOMPSAT-3A와 Sentinel-2는 서로 다른 격자 원점을 가지므로, 1:4 정수 배율 정합을 위한 공통 기준 격자의 정의가 필요하다. 공간적 불일치는 후속 방사 및 MTF 모사 과정에서 평균제곱오차 (mean squared error, MSE) 기반 목적 함수의 오차 증폭을 유발하므로, 서브픽셀 수준의 정밀한 위치 보정이 선행되어야 한다. 본 연구에서는 NASA Harmonized Landsat Sentinel-2(HLS) 프레임워크(Claverie et al., 2018)에서 제안된 공통 기준 격자 방식을 참고하여, 두 영상 교집합 영역의 중심을 원점으로 하는 공통 격자를 정의하고 각 센서를 이 격자에 독립적으로 투영한 뒤 쌍선형 보간(bilinear resampling)을 수행하였다. 공통 격자 투영 이후에도 두 센서 간에는 서브 픽셀 수준의 오차가 존재할 수 있다. 이를 보정하기 위해 위상 상관(Phase Correlation) 기법 (Kuglin and Hines, 1975; Foroosh et al., 2002)을 채택하였다. 최종적으로 KOMPSAT-3A는 896×896 화소 (GSD 2.5 m), Sentinel-2는 224×224 화소(GSD 10 m) 크기를 가지는 영상모사를 위한 데이터쌍들을 구축하였다.

C. 방사 모사

서로 다른 궤도와 취득 시기를 가진 두 영상은 대기 상태와 태양-센서 관측 기하에 기인한 방사적 불일치를 내포하므로, KOMPSAT-3A의 방사 특성을 Sentinel-2 수준으로 모사하는 과정이 필수적이다.

광학 위성 센서에서 DN와 대기 상단 복사휘도(top-of-atmosphere radiance) 간의 관계는 센서별 gain과




Figure 3. Architecture of the proposed super-resolution model: Sentinel-2 input is encoded by Prithvi-EO with LoRA, unpacked to full resolution, fused with shallow features via skip connection, refined through hybrid attention blocks, and upsampled via PixelShuffle

offset에 의해 선형으로 정의된다(Chander et al., 2009). 두 센서가 동일 지표를 관측할 때 각각의 Linear Calibration Model을 연립하면, 센서 간 DN 변환 역시 다음과 같은 선형 관계로 유도된다.

$$DN_K^{sim} = \alpha \cdot DN_K + \beta \quad (1)$$

where, DN_K denotes original KOMPSAT-3A pixel value, DN_K^{sim} denotes radiometrically simulated pixel value mapped to Sentinel-2 level, α denotes gain coefficient, β denotes offset coefficient

실제 영상에서는 대기 조건 차이, 구름·그림자, 지표 피복 변화 등으로 인해 이 선형 관계에서 크게 벗어나는 이상 화소가 존재한다. 이를 처리하기 위해 본 연구에서는 두 단계의 이상치 제거를 수행하였다. 먼저 두 센서 간 화소값 비율이 $[0.5, 2.0]$ 범위를 벗어나는 화소를 계수 산정 대상에서 배제하였으며, 이후 잔여 이상치에 대한 강건성 확보를 위해 IR-MAD(Nielsen, 2007) 기법에 기반한 가중 선형 회귀로 α, β 를 추정하였다.

D. MTF 기반 열화 모사

광학 위성 센서는 각기 다른 변조전달함수(MTF)를 가지므로, KOMPSAT-3A 영상을 Sentinel-2의 공간 해상력 수준으로 변환하기 위한 MTF 모사가 필수적이다. 센서 고유의 최적 MTF 파라미터를 추정하기 위해, 본 연구에서는 KOMPSAT-3A 영상에 가상의 열화를 적용한 영상과 실제 Sentinel-2 영상 간의 MSE가 최소화되는 지점을 탐색하는 최적화 기법을 적용하였다. 이상치는 목적 함수 값을 비정상적으로 증폭시켜 MTF 추정 결과를 심각하게 왜곡할 수 있다. 이를 방지하고자 2.1절의 C의 방사 모사 단계와 동일한 화소 필터링을 적용하여 최적화 연산에서 이상치를 전면 배제하였다.

2.2. 모델 구조

본 연구에서 제안하는 초해상화 모델은 인코더, 디코더, 손실함수로 구성된다. 인코더는 Prithvi-EO v2를 기반으로 LoRA(Hu et al., 2022)를 적용하여 사전 학습된 지식을 보존하면서 초해상화 태스크에 적응하도록 설계되었다. 디코더는 인코더의 고수준 의미 특징과 원본 저해상도 영상의 저수준 공간 정보를 결합하고, Hybrid Attention Block(HAB)(Chen et al., 2023)를 통해 고주파 텍스처를 단계적으로 복원한다. 손실함수는 픽셀 단위 복원 정확도, 경계선 선명도, 분광 특성 보존을 동시에 최적화하는 다중 손실 구조로 정의된다.

A. 인코더

본 연구는 NASA와 IBM이 공동 개발한 위성 영상 특화 파운데이션 모델 Prithvi-EO v2를 인코더로 채택하였다. Prithvi-EO v2는 HLS 데이터셋 기반 MAE 방식의 자기지도학습으로 사전 학습된 ViT 기반 모델로, 토지 피복 분류 및 홍수 탐지 등 다양한 원격탐사 태스크에서 우수한 일반화 성능이 검증된 바 있다.

Prithvi-EO v2는 6개 분광 밴드를 요구하나 본 연구의 데이터셋은 4개 밴드(B, G, R, NIR)로 구성되므로, 부족한 2개 채널에 Zero-패딩을 적용하여 입력 차원을 확장하였다(Hsu and Tseng, 2024). 미세 조정에는 LoRA를 적용하여 사전 학습된 가중치를 동결하고 저랭크 행렬만을 학습함으로써, 원격탐사 도메인 지식을 보존하면서 초해상화 태스크에 효율적으로 적응하도록 하였다.

B. 디코더

디코더는 Unpatching 및 Skip Connection을 통한 특징 정렬, Hybrid Attention Block를 통한 특징 정제, PixelShuffle 기반 Residual Learning을 통한 최종 복원의 세 단계로 구성된다.

(1). Unpatching 및 Skip Connection

인코더 출력 패치 토큰을 Stride 4의 전치 합성곱 두 차례를 통해 공간 해상도를 14×14 에서 224×224 로 점진적으로 확장한다. 각 단계 사이에 스무딩 필터를 배치하여 격자 결함을 억제하였다. 또한 원본 저해상도 영상을 얇은 합성곱 계층에 통과시켜 추출한 저수준 공간 특징을 스킵 커넥션으로 직접 전달하여 공간 정보 손실을 보완하였다.

(2). Hybrid Attention Block

정렬된 두 특징 맵을 채널 축으로 결합한 후 1×1 합성곱으로 융합하고, HAB을 통해 고주파 텍스처를 정제한다. HAB는 3×3 Depthwise Convolution으로 공간 특징을 추출한 뒤, 채널 어텐션과 공간 어텐션을 순차적으로 적용하여 건물 윤곽 및 도로 경계와 같은 핵심 엣지 영역을 집중적으로 강조한다.

(3). Residual Learning

정제된 특징 맵은 PixelShuffle(Shi et al., 2016)을 통해 다채널 특징 정보를 공간 차원으로 재분배하며 최종 타겟 해상도로 확장된다. 출력단에는 Global Residual Learning(Kim et al., 2016)을 적용하여, Bicubic 보간 영상을 기저로 고주파 잔차 성분만을 예측하여 더하는 방식으로 최종 고해상도 영상을 생성한다. 이는 모델의 학습 안정성과 수렴 속도를 향상시킨다.

C. 손실함수

본 손실함수는 픽셀 단위 복원 정확도, 경계선 선명도, 분광 특성 보존을 동시에 최적화하기 위해 세 가지 손실 함수의 가중 합으로 정의된다.

$$\mathcal{L}_{total} = \lambda_1 \mathcal{L}_{L1} + \lambda_2 \mathcal{L}_{edge} + \lambda_3 \mathcal{L}_{sam} \quad (2)$$

here $\lambda_1, \lambda_2, \lambda_3$ denote the weighting coefficients for each loss term.

(1). L1 손실함수

L1은 실제 영상과 예측 영상 간의 픽셀 단위 절대 오차를 최소화한다. 평균 제곱 오차(L_2) 대비 이상치에 강건하며, 전반적인 밝기 분포를 안정적으로 복원한다.

$$\mathcal{L}_{L1} = \frac{1}{N} \sum_{i=1}^N |\hat{Y}_i - Y_i| \quad (3)$$

(2). Edge 손실함수

소벨(Sobel) 연산자로 추출한 그래디언트 오차를 최소화하여 건물 윤곽선, 도로망 등 고주파 공간 디테일을 강화한다.

$$\mathcal{L}_{edge} = \frac{1}{N} \sum_{i=1}^N |\nabla \hat{Y}_i - \nabla Y_i| \quad (4)$$

(3). SAM 손실함수

분광 벡터 간 각도 차이를 최소화하여 픽셀 밝기 변화에 무관하게 지표물 고유의 분광 반사도 비율을 보존한다.

$$\mathcal{L}_{sam} = \frac{1}{N} \sum_{i=1}^N \text{across} \left(\frac{\hat{Y}_i \cdot Y_i}{\|\hat{Y}_i\| \|Y_i\|} \right) \quad (5)$$

where $\hat{Y}_i$ denotes the predicted image, Y_i denotes the reference image (KOMPSAT-3A), N denotes the number of pixels, and ∇ denotes the edge map extracted via the Sobel operator.

2.3. 학습 및 평가방법

A. 학습 데이터셋

전처리된 모사 K3A(GSD 10m, 저해상도) - 원본 K3A(GSD 2.5m, 고해상도) 영상 쌍 519개를 씌 단위로 학습용 415개, 검증용 51개, 테스트용 53개로 분할하였다. 학습 데이터에는 상하좌우 반전 및 90° 임의 회전을 조합한 16가지 변환을 매 에포크마다 적용하여 다양한 지표 방향성에 대한 모델의 일반화 성능을 확보하였다..

B. 파라미터

최적 하이퍼파라미터 탐색을 위해 그리드 탐색(Grid Search)을 수행하였으며, 검증 손실 기준으로 최적 조합을 선정하였다. 학습 설정 및 환경은 아래 표와 같다.

Table1. Experimental setup and hyperparameter configuration.

Parameter	Value	Parameter	Value
Lora Rank(r)	16	L1 weight	1.0
Lora Alpha	16	L_SAM Weight	0.15
Lora Dropout	0.1	L_edge weight	0.3
Learning Rate	1e-4	Optimizer	AdamW
Epoch	180	Batch size	8

3. 연구결과

3.1. 영상 모사 결과

제안한 영상 모사 파이프라인의 정확도를 검증하기 위해, 공통 격자(S2 10 m)로 정렬된 K3A 원본(Before)과 모사 영상(After)을 각각 실제 Sentinel-2 영상과 비교하여 밴드별 정량 지표를 산출하였다. 그 결과 제안 방식은 RMSE는 약 62.05%, MAE는 약 69.3% 개선되었다. 보정 효과는 두 센서 간 분광 응답 차이가 상대적으로 큰 Green-Red-NIR에서 특히 뚜렷하다.

Table2. Performance evaluation of the proposed image simulation pipeline across four bands, compared against the K3A original (baseline). All metrics are computed on S2 10 m grid after average-pooling K3A to match the Sentinel-2 pixel size. RMSE, MAE, and Bias are reported in DN.

Band	RMSE		MAE		Pearson r	
	Bicubic	Proposed	Bicubic	Proposed	Bicubic	Proposed
Blue	876.51	405.41	724.19	276.32	0.6173	0.7261
Green	1182.51	370.10	1040.90	241.22	0.5438	0.6314
Red	1004.14	374.31	860.80	234.99	0.2519	0.6202
NIR	1871.63	553.74	1599.98	383.63	0.8097	0.7889

Pearson 상관계수(r)의 경우 Red 밴드에서 0.252에서 0.620으로 가장 큰 개선이 관측되었는데, 이는 K3A와 Sentinel-2의 Red 밴드 SRF(Spectral Response Function) 차이가 다른 밴드보다 크기 때문에 SRF 기반 방사 모사로 얻는 이득이 가장 크게 반영된 결과로 해석되며 Sentinel-2에 성공적으로 정합되었음을 보여준다.




Figure 4. Comparison of K3A original, simulated S2, and Sentinel-2 on a validation chip (A) RGB composites, (B) magnified subregions, (C) per-band DN histograms. The simulation better matches Sentinel-2 in both tone and distribution than the original.

이러한 정량적 개선은 Fig. 4의 육안 비교와 히스토그램 분포에서도 동일하게 확인된다. Fig. 4은 임의의 검증용 칩에 대해 (A) RGB 합성 영상, (B) MTF 저역필터와

평균 풀링 후의 확대 영상, (C) 네 밴드의 DN 히스토그램을 KOMPSAT-3A 원본, 모사 영상, Sentinel-2와 나란히 비교한 것이다. (B)의 확대 영역에서 모사 영상이 S2의 공간적 평활화 정도를 픽셀 단위로 따라가는 것을 볼 수 있다. (C)의 밴드별 히스토그램에서는 모사 영상이 분포의 중심과 확산(spread)이 Sentinel-2와 유사하게 이동하여 Table 2의 RMSE 개선을 뒷받침한다.

이상의 결과는 제안 파이프라인이 단순한 해상도 변환이나 선형 스케일링을 넘어, 두 센서 간 분광 응답 및 복사 특성 차이를 반영한 도메인 매칭(domain matching)을 달성하였음을 의미하며, 이렇게 모사된 영상은 K3A-Sentinel-2 페어 기반 초해상화 학습을 위한 고품질 레퍼런스로 활용될 수 있다.

3.2. 초해상화 결과

A. 정성적 평가

지표 피복 특성에 따른 복원 성능을 검증하기 위해 농촌, 도심, 산림 지역의 대표 샘플을 분석하였다. 농촌 지역에서는 필지 경계 및 도로 윤곽부의 블러 현상이 억제되어 경계 복원 성능이 향상되었음을 확인하였다. 도심 지역은 인공 구조물의 정형적 구조로 인해 공간적 변화의 폭은 상대적으로 작았으나, 분광 정보 재구성을 통해 원본에 근접한 색감으로 개선되었다. 산림 지역에서는 저해상도에서 손실된 미세 식생 질감이 정교하게 재구성되었으며, 지표면의 복잡한 구조적 특징을 보존하는 모




Figure 5. Qualitative comparison of SR results. From left: Simulated K3A (Input), Bicubic (Baseline), Proposed Model, and Original K3A (GT). Rows represent different land cover types.

델의 성능을 시사한다.

B. 정량적 평가

제안 모델의 성능을 정량적으로 검증하기 위해 테스트 셋 53쌍에 대해 PSNR, SSIM, SAM, Edge RMSE 네 가지

지표를 Bicubic 보간법과 비교하였다. PSNR과 SSIM은 원본 K3A(2.5m)와의 화소 복원 정확도 및 구조적 유사성을 평가하며 값이 클수록, SAM과 Edge RMSE는 각각 분광 보존성과 경계 선명도를 측정하며 값이 작을수록 우수하다.

제안 모델은 Bicubic 보간 대비 모든 평가 지표에서 일관된 성능 향상을 보였다. PSNR은 23.242dB에서 28.741dB로 5.50dB 향상되어 전반적인 화소 복원 품질이 크게 개선되었다. SSIM은 0.769에서 0.824로 증가하여 건물·도로 등 주요 지물의 구조적 유사성 및 공간적 일관성이 향상되었음을 확인하였다. SAM은 0.083에서 0.055로 감소하여 다중 분광 밴드 간 반사도 비율이 보다 충실히 보존되었음을 보여주며 이는 제안된 모델이 분광 왜곡을 효과적으로 억제함을 시사한다. Edge RMSE 또한 0.138에서 0.103으로 감소하며 경계 복원 품질이 유의미하게 향상되었음을 보여준다.

Table3. Quantitative comparison of super-resolution performance between Bicubic interpolation and the proposed model. PSNR and SSIM indicate higher-is-better, while SAM and Edge RMSE indicate lower-is-better.

Metric	Bicubic	Model	Gain
PSNR	23.242	28.741	+5.50dB
SSIM	0.769	0.824	+0.055
SAM	0.083	0.055	-0.028
Edge RMSE	0.138	0.103	-0.035

C. 통계적 유의성 검증

제안 모델의 성능 향상에 대한 객관적 신뢰도를 검증하고자 통계적 유의성 검정을 실시하였다. 분석 결과, PSNR($p < 0.001$)과 SSIM($p < 0.001$) 등 모든 지표에서 통계적으로 유의미한 차이가 확인되었다. 특히 PSNR의 효과 크기(Cohen's d)는 1.2314로 나타나 기존 방식 대비 뚜렷한 화질 개선 효과를 입증하였다. 또한 Wilcoxon Signed-Rank Test를 통해 SAM과 Edge RMSE에서도 유의미한 성능 향상($p < 0.05$)이 관찰됨에 따라, 본 모델이 분광 정보 보존 및 경계 복원 측면에서 강건성을 보유했음을 통계적으로 입증하였다.

Table4. Statistical significance of performance improvements. Parametric and non-parametric tests confirm significant gains across all metrics ($p < 0.01$). (** / *** denote $p < 0.01$ and $p < 0.001$, respectively.)

Metric	Statistical Test	p-value	Cohen's d
PSNR	Paired t-test	$< 0.001^{***}$	1.231
SSIM	Wilcoxon Signed-Rank	$< 0.001^{***}$	0.897
SAM	Wilcoxon Signed-Rank	$< 0.001^{***}$	-0.699
Edge	Wilcoxon	0.005^{**}	-0.396

RMSE	Signed-Rank		
------	-------------	--	--

3.3. 절제 실험

제안된 모델 디코더의 핵심 구성 요소인 Skip Connection, HAB, Residual Learning의 기여도를 분석하기 위해 절제 실험을 수행하였다. 실험은 학습에 사용된 모사 데이터셋과 실제 위성 영상 데이터셋(Sentinel-2) 두 환경에서 진행하였으며, 세부 모델 변형 구성은 다음 표5와 같다.

Table 5 presents four distinct model variants (Cases A–D) designed to evaluate the contribution of each key module. Case A denotes the full proposed model, while Cases B, C, and D are configured by systematically excluding or replacing the skip connections, the Hybrid Attention Block, and the bicubic residual branch, respectively.

Case	Skip Connection	HAB	Bicubic Residual
A	O	O	O
B	X	O	O
C	O	X	O
D	O	O	X

표 6,7은 두 환경에서 수행한 절제 실험의 결과이다. Skip Connection을 제거한 Case B는 두 데이터셋 모두에서 PSNR 및 SSIM이 가장 큰 폭으로 하락하였으며, 실제 데이터셋에서는 SAM이 Bicubic 대비 오히려 악화($0.0885 \rightarrow 0.0941$)되었다. 이는 저해상도 영상의 저주파 공간 정보를 손실 없이 전달하는 것이 복원 성능의 핵심임을 시사한다.

HAB를 일반 Convolution으로 대체한 Case C는 모사 데이터셋에서 일시적으로 높은 수치를 기록하였으나, 실제 데이터셋에서는 Full 모델(PSNR 23.44)이 Case C(22.98)를 상회하였다. 합성 데이터의 단순한 분포에서는 일반 Convolution이 유리할 수 있으나, 실제 위성 영상의 복잡한 노이즈·텍스처 환경에서는 HAB의 어텐션 메커니즘이 보다 강건한 일반화 성능을 제공함을 확인하였다.

Residual Learning을 제거한 Case D는 전반적인 지표에서 소폭 하락하였으며, 잔차 학습 구조가 에지 및 고주파 세부 성분 복원에 기여하고 있음을 보여준다.

Table 6. Quantitative comparison on synthetic training data. Values in parentheses denote absolute improvement over the Baseline. Case C achieves the best performance across all metrics.

Case	PSNR	SSIM	SAM	Edge RMSE
A	28.741 (+5.50)	0.824 (+0.055)	0.055 (-0.028)	0.103 (-0.035)
B	27.061 (+3.82)	0.785 (+0.016)	0.061 (-0.022)	0.114 (-0.024)
C	30.213 (+6.97)	0.849 (+0.080)	0.047 (-0.036)	0.094 (-0.044)
D	28.448 (+5.21)	0.810 (+0.041)	0.054 (-0.029)	0.106 (-0.032)
Base	23.242	0.769	0.083	0.138

Table 7. Quantitative comparison with bicubic interpolation on real Sentinel-2 imagery. Values in parentheses denote absolute change relative to bicubic. The proposed model outperforms bicubic across all metrics.

Case	PSNR	SSIM	SAM	Edge RMSE
A	23.441 (+1.529)	0.702 (+0.031)	0.086 (-0.002)	0.115 (-0.0004)
B	22.958 (+1.046)	0.698 (+0.026)	0.094 (+0.006)	0.120 (+0.005)
C	22.982 (+1.070)	0.691 (+0.020)	0.095 (+0.007)	0.111 (-0.004)
D	23.267 (+1.355)	0.697 (+0.025)	0.090 (+0.001)	0.115 (+0.0002)
Base	21.912	0.672	0.089	0.115

4. 결론

본 연구에서는 실제 위성 센서의 물리적 열화 및 분광 특성을 반영한 학습 데이터셋을 구축하고, Geo Foundation Model인 Prithvi-EO-2.0을 인코더로 활용하여 Sentinel-2(10m) 영상을 KOMPSAT-3A(2.5m) 해상도 수준으로 향상시키는 초해상화 프레임워크를 제안하였다. 정량적 평가 결과, 제안 모델은 Bicubic 보간 대비 PSNR +5.50dB, SSIM +0.055의 성능 향상을 달성하였다. PSNR의 향상은 두 센서 간 이질적인 방사 특성이 성공적으로 매핑되었음을 의미하며, SSIM 개선은 도로·건물·지형 경계 등 핵심 객체의 구조적 형태가 안정적으로 복원되었음을 보여준다. SAM 지표의 개선은 초해상화 과정에서 다중분광 밴드 간 분광 반사도 비율이 충실히 보존되었음을 확인한다.

본 연구의 프레임워크는 접근성이 높은 S2 영상으로 K3A 수준의 공간 정보를 확보할 수 있어, 광역 모니터링

에 수반되는 비용과 시간적 제약을 실질적으로 경감할 수 있다. 본 결과는 물리 기반 열화 모델링과 GFM의 지리공간적 사전 지식의 결합이 위성 영상 초해상화에 효과적으로 기여할 수 있음을 시사하며, 향후 다양한 이종 센서 간 융합 및 해상도 향상 연구의 기반 기술로 활용될 수 있을 것으로 기대된다.

참고문헌

1. Ali, I., et al., 2024, Remote sensing for agricultural and forestry monitoring: A review of current deep learning applications, International Journal of Remote Sensing, Vol. 45, No. 3, pp. 890–915.
2. Chen, X., Wang, X., Zhou, J. and Dong, C., 2023, Activating more pixels in image super-resolution via hybrid attention transformer, Proc. of CVPR, IEEE/CVF, Vancouver, Canada, pp. 20731–20741.
3. Claverie, M., Ju, J., Masek, J. G., Dungan, J. L., Vermote, E. F., Roger, J. C., Skakun, S. and Justice, C. O., 2018, The Harmonized Landsat and Sentinel-2 surface reflectance dataset, Remote Sensing of Environment, Vol. 219, pp. 145–161.
4. European Environment Agency, 2020, Use of remote sensing in climate change adaptation, Research report, EEA, European Union.
5. Foroosh, H., Zerubia, J. B. and Berthod, M., 2002, Extension of phase correlation to sub pixel registration, IEEE Transactions on Image Processing, Vol. 11, No. 3, pp. 188–200.
6. Gasperini, F., Michoud, G., Rosso, D. and Bruzzone, L., 2022, Super-resolution of Sentinel-2 images: A review, IEEE Geoscience and Remote Sensing Magazine, Vol. 10, No. 2, pp. 200–225.
7. Hu, E. J., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L. and Chen, W., 2022, LoRA: Low-rank adaptation of large language models, Proc. of ICLR, Online, pp. 1–13.
8. Jakubik, J., Fraccaro, P., Szwarcman, D., Berg, F., Garioud, A., Roy, S. and Hamann, H., 2024, Prithvi-WAP: A foundation model for regional-scale water and agriculture applications, arXiv:2409.06646, <http://arxiv.org/abs/2409.06646>.
9. Kim, J., Lee, J. K. and Lee, K. M., 2016, Accurate image super-resolution using very deep convolutional networks, Proc. of CVPR, IE

EE, Las Vegas, USA, pp. 1646–1654.

10. Kuglin, C. D. and Hines, D. C., 1975, The phase correlation image alignment method, *Proc. of IEEE 1975 International Conference on Cybernetics and Society*, New York, USA, pp. 163–165.
11. Nguyen, V., et al., 2023, Bridging the domain gap in satellite image super-resolution via physical degradation modeling, *IEEE Geoscience and Remote Sensing Letters*, Vol. 20, pp. 1–5.
12. Nielsen, A. A., 2007, The iteratively reweighted multivariate alteration detection (IR-MAD) transformation for change detection in multichannel imagery, *IEEE Transactions on Image Processing*, Vol. 16, No. 9, pp. 2263–2274.
13. Qiu, C., et al., 2025, Global urban change detection using high-resolution satellite imagery and deep foundation models, *Remote Sensing of Environment*, Vol. 302, 113954.